MÁSTER EN BIG DATA APLICADO AL SCOUTING EN FUTBOL

TRABAJO FIN DE MÁSTER

DISEÑO E IMPLEMENTACIÓN DE UN MODELO INTEGRAL DE SCOUTING DATA-DRIVEN PARA LA CONSTRUCCIÓN DE UNA PLANTILLA EN LA PREMIER LEAGUE

Alumno: Salvador Álvarez Sánchez

1. RESUMEN EJECUTIVO 5
ABSTRACT 5
2. INTRODUCCIÓN Y CONTEXTUALIZACIÓN 6
2.1. Justificación del proyecto 6
2.2. Cambio de paradigma: de la intuición al dato 7
2.3. Definición del escenario simulado 7
2.4. Reglas de negocio y restricciones 7

2.5. Objetivos generales 8
2.6. Objetivos específicos 8
3. ARQUITECTURA CONCEPTUAL Y TECNOLÓGICA DEL PROYECTO 8
3.1. Infraestructura de datos 9
3.2. Fuentes de información 9
3.2.1. Datos de rendimiento deportivo 9
3.2.2. Datos económicos y contractuales 10
3.2.3. Procedimiento de extracción automatizada 10
3.3. Herramientas tecnológicas utilizadas 11
3.4. Diseño general del flujo de trabajo 11
4. METODOLOGÍA APLICADA: MODELO CRISP-DM 13
4.1. Comprensión del negocio 13
4.2. Comprensión de los datos 13
4.3. Preparación y transformación de los datos 14
4.3.1. Normalización per 90 minutos 14
4.3.2. Estandarización estadística 14
4.3.3. Filtrado estructural 14
4.4. Modelado 14
4.4.1. Segmentación de perfiles (Clustering) 15
4.4.2. Búsqueda de similitudes y reemplazos 15
4.5. Evaluación 15
4.6. Despliegue 15
5. DESARROLLO TÉCNICO DEL MODELO: INGENIERÍA DE DATOS Y MACHINE LEARNING APLICADO 16
5.1. Proceso ETL en Python y Construcción del Dataset Maestro 16
5.1.1. Extracción automatizada 16
5.1.2. Transformación y limpieza 17
5.2. Normalización Estadística y Ajuste por Liga 17
5.2.1. Normalización per 90 minutos 17
5.2.2. Estandarización mediante percentiles 17
5.2.3. Ajuste por competitividad de liga 17
5.3. Definición de KPIs por Posición 17
5.4. Construcción del Weighted Performance Score 18
5.5. Integración Económica y Score Final 18

5.6. Segmentación de Perfiles mediante Clustering (K-Means) 19
5.7. Similitud del Coseno y Búsqueda de Reemplazos 19
5.8. Modelo de Detección Sub-21 20
5.9. Exportación y Trazabilidad 20
6. DESARROLLO DE LA HERRAMIENTA BI 20
6.1. Diseño del Dashboard 21
6.2. Estructura de la interfaz 21
6.3. Visualizaciones clave 21
6.3.1. Dashboard 1 — Análisis Coste–Rendimiento 22
6.3.2. Dashboard 2 — Planificación Estratégica del Once Ideal 22
6.4. Simulación de escenarios 23
6.5. Síntesis operativa de la herramienta 23
7. CASO PRÁCTICO: CONSTRUCCIÓN DEL ONCE IDEAL 23
7.1. Estrategia presupuestaria 24
7.2. Selección por Líneas 24
7.2.1. Portería 24
7.2.2. Línea de Tres Centrales 25
Selección final 25
7.2.3. Carrileros 26
7.2.4. Doble Mediocentro 27
7.2.5. Mediapuntas Interiores 27
7.2.6. Delantero Centro 28
7.3. Integración de talento Sub-21 29
7.4. Auditoría económica 30
7.5. Análisis de edad media 32
8. DISCUSIÓN DE RESULTADOS 32
8.1. Validación del modelo 32
8.2. Fortalezas del modelo 34
8.3. Limitaciones del estudio 35
9. CONCLUSIONES Y LÍNEAS FUTURAS 35
9.1. Conclusiones estratégicas 35
9.2. Integración de Tracking Data 36
9.3. Inteligencia Artificial Generativa 36

10. BIBLIOGRAFÍA 36
11. ANEXOS 37
11.1. Script completo en Python 37
11.2. Dataset final para Business Intelligence 38
11.3. Outputs del modelo de Machine Learning 39
11.4. Archivo del Dashboard Interactivo 39

1. RESUMEN EJECUTIVO

(Escalón 1: Enfoque Directivo)
El presente Trabajo Fin de Máster desarrolla el diseño e implementación de un modelo integral de Scouting Data-Driven aplicado a la Dirección Deportiva de un club de la Premier League en un escenario simulado de alta exigencia competitiva. El proyecto parte de la incorporación de un nuevo inversor que establece un presupuesto máximo de 350 millones de euros con el objetivo estratégico de construir un once titular capaz de competir por la clasificación a la UEFA Champions League.
La planificación deportiva se articula bajo la dirección técnica de Xabi Alonso, adoptando su sistema táctico 1-3-4-2-1 como marco estructural del proyecto. En consecuencia, la selección de jugadores no responde a criterios genéricos de rendimiento, sino a las demandas específicas posicionales, físicas y tácticas que exige dicho modelo en el contexto de la Premier League, considerada una de las competiciones más intensas y económicamente exigentes del fútbol europeo.
El modelo establece un conjunto de reglas de negocio estrictas que condicionan la toma de decisiones:

- Límite máximo de edad de 30 años.
- Incorporación obligatoria de al menos dos jugadores Sub-21 en el once titular.
- Priorización estratégica de agentes libres y perfiles infravalorados.
- Cumplimiento estricto del presupuesto total de 350M€.

Metodológicamente, el trabajo se desarrolla bajo el marco CRISP-DM, integrando procesos de Ingeniería de Datos (ETL), construcción de un dataset maestro multi-liga, normalización estadística (métricas per 90, percentiles y ajuste por competitividad de liga) y diseño de KPIs tácticos específicos por posición. Sobre esta base, se aplican técnicas de Machine Learning no supervisado, concretamente Clustering (K-Means) y algoritmos de Similitud del Coseno, con el objetivo de detectar perfiles óptimos, talento joven proyectable y oportunidades de mercado infravaloradas.
El resultado final no se limita a la propuesta de un once ideal económicamente viable y tácticamente coherente, sino que culmina en la construcción de un sistema replicable de toma de decisiones, apoyado por una herramienta de visualización en Business Intelligence (Tableau), que permite simular escenarios de mercado y optimizar la asignación presupuestaria por líneas.
La principal aportación del proyecto reside en la profesionalización del proceso de scouting mediante un enfoque cuantitativo estructurado, reduciendo la subjetividad tradicional y proporcionando un modelo exportable a contextos reales de Dirección Deportiva en entornos de alta competencia financiera.

ABSTRACT

This Master's Thesis presents the design and implementation of an integral Data-Driven scouting model applied to the Sporting Direction of a Premier League club within a high-demand competitive scenario. The project simulates the arrival of a new investor who

allocates a maximum budget of €350 million to build a starting eleven capable of competing for UEFA Champions League qualification.
The squad planning process is structured around Xabi Alonso's tactical framework (1-3-4-2-1), ensuring that player recruitment aligns with specific positional, physical, and tactical demands required by the Premier League's intensity and financial competitiveness.
The model operates under strict business constraints:

- Maximum age limit of 30 years.
- Mandatory inclusion of at least two U-21 players in the starting eleven.
- Strategic prioritization of free agents and undervalued profiles.
- Strict compliance with the €350M budget.

The methodology follows the CRISP-DM framework, integrating data engineering processes, multi-league dataset construction, statistical normalization (per 90 metrics, percentiles, and league competitiveness adjustment), and the definition of position-specific tactical KPIs. Unsupervised Machine Learning techniques, including K-Means clustering and cosine similarity algorithms, are applied to identify optimal player profiles, projectable young talent, and market inefficiencies.
The project concludes with the proposal of an economically viable and tactically coherent starting eleven, supported by a Business Intelligence dashboard developed in Tableau that enables market scenario simulation and optimized budget allocation.
The core contribution of this thesis lies not merely in player selection, but in the development of a replicable decision-making framework that professionalizes the scouting process and reduces uncertainty in high-investment sporting environments.

2. INTRODUCCIÓN Y CONTEXTUALIZACIÓN

2.1. Justificación del proyecto

El fútbol profesional contemporáneo se caracteriza por una creciente complejidad competitiva, financiera y estratégica. La globalización del mercado de fichajes, el aumento exponencial de los derechos televisivos y la presión por obtener resultados inmediatos han convertido la toma de decisiones en la Dirección Deportiva en un proceso de alto riesgo e impacto económico.
En este contexto, la inversión en fichajes ya no puede basarse exclusivamente en la experiencia subjetiva, la intuición o la reputación mediática de los jugadores. La magnitud de las operaciones y la exigencia competitiva obligan a los clubes a reducir la incertidumbre y a profesionalizar sus procesos mediante el uso sistemático del dato.
El presente Trabajo Fin de Máster surge precisamente de esa necesidad: diseñar un modelo estructurado de Scouting Data-Driven que permita tomar decisiones fundamentadas, medibles y coherentes con una identidad táctica definida, integrando análisis de rendimiento y análisis económico en un único sistema de evaluación.

2.2. Cambio de paradigma: de la intuición al dato

Tradicionalmente, el scouting se ha apoyado en la observación cualitativa del talento, el conocimiento acumulado de los ojeadores y la experiencia previa de los responsables deportivos. Si bien estos elementos continúan siendo relevantes, el avance tecnológico y la disponibilidad masiva de datos han transformado el paradigma de análisis en el fútbol profesional.

El desarrollo de plataformas de datos avanzados, métricas como los goles esperados (xG), asistencias esperadas (xA) o acciones progresivas, y la incorporación de herramientas de Machine Learning permiten hoy segmentar perfiles, detectar patrones ocultos y comparar jugadores en contextos competitivos distintos.

Este cambio de paradigma no implica sustituir la intuición por completo, sino complementarla con evidencia cuantitativa. El modelo propuesto en este trabajo adopta un enfoque predominantemente analítico, reduciendo la subjetividad en la primera fase de filtrado y priorizando decisiones respaldadas por métricas estructuradas

2.3. Definición del escenario simulado

La Premier League representa uno de los entornos más exigentes del fútbol mundial tanto a nivel físico como económico. La intensidad de juego, el ritmo competitivo, la capacidad financiera de los clubes y la presión mediática convierten a esta liga en un escenario de máxima dificultad.

En este contexto, la planificación deportiva debe atender simultáneamente a tres dimensiones:

- Competitividad inmediata.
- Sostenibilidad económica.
- Proyección futura de activos.

La dificultad de competir contra clubes consolidados obliga a adoptar estrategias inteligentes de mercado, detectando talento infravalorado y optimizando cada euro invertido.

2.4. Reglas de negocio y restricciones

El proyecto plantea un escenario simulado en el que un club recién ascendido a la Premier League recibe la entrada de un nuevo inversor con un presupuesto máximo de 350 millones de euros destinado a la construcción de un once titular competitivo.

Como parte de la nueva estructura deportiva, el club incorpora a Xabi Alonso como entrenador principal del proyecto. El técnico aporta una identidad táctica clara basada en el sistema 1-3-4-2-1, esquema que le ha proporcionado mayor estabilidad y éxito competitivo en experiencias previas.

En consecuencia, la planificación de plantilla no se diseña desde un enfoque neutro, sino alineada específicamente con las demandas estructurales de dicho sistema. Este modelo táctico exige:

- Centrales con capacidad de salida limpia de balón y amplitud defensiva.
- Carrileros profundos capaces de asumir funciones ofensivas similares a extremos abiertos.

- Mediocentros con equilibrio entre construcción y presión.
- Mediapuntas interiores con creatividad, movilidad entre líneas y capacidad de presión tras pérdida.
- Delantero con movilidad, asociación y presencia en área.

El diseño del modelo analítico se orienta, por tanto, a identificar perfiles que encajen en esta estructura táctica concreta.

2.5. Objetivos generales

El escenario simulado establece una serie de reglas estratégicas que condicionan la construcción de la plantilla:

- Límite máximo de edad de 30 años, con el objetivo de garantizar intensidad física y potencial de revalorización.
- Incorporación obligatoria de al menos dos jugadores Sub-21 en el once titular.
- Priorización de agentes libres y perfiles infravalorados para optimizar la eficiencia económica
- Cumplimiento estricto del presupuesto total de 350 millones de euros.

Estas restricciones obligan a diseñar un modelo de selección que equilibre rendimiento deportivo inmediato y sostenibilidad financiera.

2.6. Objetivos específicos

Diseñar e implementar un modelo integral de Scouting Data-Driven que permita construir una plantilla competitiva en la Premier League bajo restricciones presupuestarias, tácticas y estratégicas previamente definidas.

Objetivos Específicos

- Traducir el sistema táctico 1-3-4-2-1 en métricas cuantificables por posición.
- Diseñar KPIs específicos adaptados a las demandas de cada rol
- Aplicar técnicas de Machine Learning no supervisado para segmentar perfiles de jugadores por estilo real de juego.
- Detectar oportunidades de mercado con alto potencial de retorno
- Integrar talento Sub-21 sin comprometer el rendimiento inmediato.
- Desarrollar una herramienta de visualización en Business Intelligence que facilite la toma de decisiones.

3. ARQUITECTURA CONCEPTUAL Y TECNOLÓGICA DEL PROYECTO

El diseño del modelo integral de Scouting Data-Driven requiere una arquitectura sólida que garantice coherencia metodológica, integridad de datos y capacidad de escalabilidad. Este capítulo describe la infraestructura conceptual y tecnológica que sustenta el proyecto, así como las herramientas empleadas y el flujo general de trabajo implementado.

La arquitectura no se limita a un entorno técnico, sino que responde a una lógica estratégica: transformar datos dispersos en un sistema estructurado de apoyo a la toma de decisiones en la Dirección Deportiva.

3.1. Infraestructura de datos

La infraestructura de datos del proyecto se diseñó bajo un principio de centralización y trazabilidad. El núcleo del sistema lo constituye un **dataset maestro multi-liga**, construido a partir de información estadística de las principales competiciones europeas.
La estructura se organiza en tres niveles:

1. **Nivel bruto (Raw Data)**
   Datos extraídos directamente de las fuentes originales, sin transformación significativa.
2. **Nivel procesado (Processed Data)**
   Datos limpiados, normalizados y estructurados bajo claves únicas que permiten su integración transversal.
3. **Nivel analítico (Analytical Layer)**
   Dataset final enriquecido con métricas avanzadas, variables económicas y atributos contractuales, preparado para modelado estadístico y Machine Learning.

El dataset maestro integra información de:

- Premier League
- La Liga
- Bundesliga
- Serie A
- Ligue 1
- Primeira Liga
- Championship

Tras la consolidación y depuración estructural, el sistema trabaja con aproximadamente 900 jugadores únicos elegibles bajo las restricciones de edad y mercado definidas en el proyecto.
La clave compuesta utilizada para garantizar unicidad en los registros está formada por:

- Player
- Squad
- League
- Season

Este diseño evita duplicidades y permite la integración incremental de nuevas métricas sin pérdida de información.

3.2. Fuentes de información

El modelo se nutre de dos grandes bloques de información:

3.2.1. Datos de rendimiento deportivo

Procedentes principalmente de plataformas especializadas como:

- FBref (estadísticas estándar y avanzadas)

- Métricas derivadas de modelos StatsBomb

Estas fuentes proporcionan información estructurada sobre:

- Producción ofensiva (goles, xG, xA)
- Creación de juego (pases progresivos, pases al último tercio)
- Acciones defensivas (intercepciones, tackles, duelos)
- Participación en posesión y construcción
- Métricas específicas de porteros (PSxG, porcentaje de paradas, etc.)

La elección de estas fuentes responde a su carácter público, estructurado y comparable entre ligas.

3.2.2. Datos económicos y contractuales

Para dotar al modelo de aplicabilidad real en un contexto de Dirección Deportiva, se incorporaron:

- Valor de mercado estimado (en millones de euros).
- Situación contractual (identificación de jugadores que finalizan contrato).

La integración de estas variables permite evaluar no solo el rendimiento deportivo, sino también la viabilidad financiera y la oportunidad estratégica de mercado.

3.2.3. Procedimiento de extracción automatizada

La extracción de datos se realizó mediante un proceso automatizado desarrollado en Python, empleando técnicas de web scraping estructurado.

Las estadísticas de rendimiento fueron obtenidas principalmente desde la plataforma FBref, que proporciona tablas detalladas de métricas estándar y avanzadas para múltiples competiciones europeas.

Dado que algunas tablas se encuentran embebidas en comentarios HTML, fue necesario implementar un procedimiento específico de parsing utilizando:

- BeautifulSoup para análisis estructural del HTML.
- SeleniumBase para la carga dinámica de páginas.
- Funciones personalizadas para detección de tablas ocultas por identificador (table_id).

El proceso de extracción se diseñó bajo los siguientes principios:

- Automatización por liga mediante iteración sobre URLs estructuradas.
- Identificación de tablas estándar (stats_standard) y tablas avanzadas (shooting, passing, defense, possession, gca, etc.).
- Extracción diferenciada para porteros (stats_keeper y stats_keeper_adv).
- Uso de claves compuestas (Player, Squad, League, Season) para evitar duplicidades.
- Sistema incremental de integración mediante lógica de upsert para añadir métricas sin sobrescribir información existente.

La automatización permitió consolidar información de siete competiciones europeas, generando un dataset maestro reproducible y escalable.

Este enfoque garantiza trazabilidad, reproducibilidad y minimiza errores manuales en el proceso de integración de datos.

3.3. Herramientas tecnológicas utilizadas

El proyecto fue desarrollado íntegramente en Python, empleando un ecosistema orientado a Data Science y automatización.

Las principales herramientas utilizadas incluyen:

- **pandas y numpy** para manipulación de datos estructurados.
- **BeautifulSoup y SeleniumBase** para extracción automatizada de tablas estadísticas.
- **RapidFuzz** para conciliación y normalización de nombres en procesos de integración.
- **matplotlib y seaborn** para validación visual exploratoria.
- **scikit-learn** para modelado de Machine Learning (K-Means, métricas de evaluación).
- **Tableau** para el desarrollo del entorno de Business Intelligence.

La combinación de estas herramientas permitió automatizar procesos tradicionalmente manuales, garantizando reproducibilidad y eficiencia operativa.

3.4. Diseño general del flujo de trabajo

El flujo de trabajo implementado sigue una lógica secuencial alineada con el modelo CRISP-DM, que será desarrollado en el capítulo siguiente.

El proceso general puede sintetizarse en las siguientes fases:

1. **Extracción de datos (ETL inicial)**
   Descarga y consolidación de estadísticas estándar y avanzadas por liga.
2. **Normalización estructural**
   Limpieza de formatos, conversión a métricas per 90 minutos y estandarización estadística.
3. **Integración económica**
   Incorporación de valor de mercado y situación contractual.
4. **Ingeniería de características (Feature Engineering)**
   Diseño de KPIs específicos por posición y construcción de índices sintéticos de rendimiento.
5. **Modelado avanzado**
   Aplicación de Clustering y algoritmos de similitud para segmentación de perfiles.
6. **Visualización y simulación**
   Desarrollo de dashboard interactivo para toma de decisiones.

Este flujo transforma datos aislados en un sistema estructurado capaz de generar recomendaciones tácticas y económicas coherentes con el modelo de juego definido.

El proyecto sigue un flujo de trabajo estructurado que integra procesos de ingeniería de datos, análisis estadístico y técnicas de Machine Learning aplicadas al scouting futbolístico.

El pipeline comienza con la extracción automatizada de datos de rendimiento y contexto económico procedentes de diferentes fuentes abiertas. Posteriormente, los datos son

limpiados, normalizados y transformados en métricas comparables mediante ajustes por minutos jugados y estandarización estadística.

A partir de estas métricas se definen indicadores clave de rendimiento (KPIs) específicos por posición dentro del sistema táctico 1-3-4-2-1. Estos KPIs se integran en un índice sintético de rendimiento que posteriormente se complementa con técnicas de Machine Learning para detectar perfiles similares y oportunidades de mercado.

Finalmente, el modelo genera shortlists de jugadores por posición, permitiendo la construcción de un once titular optimizado que cumple las restricciones económicas, de edad y de estructura táctica definidas en el proyecto.

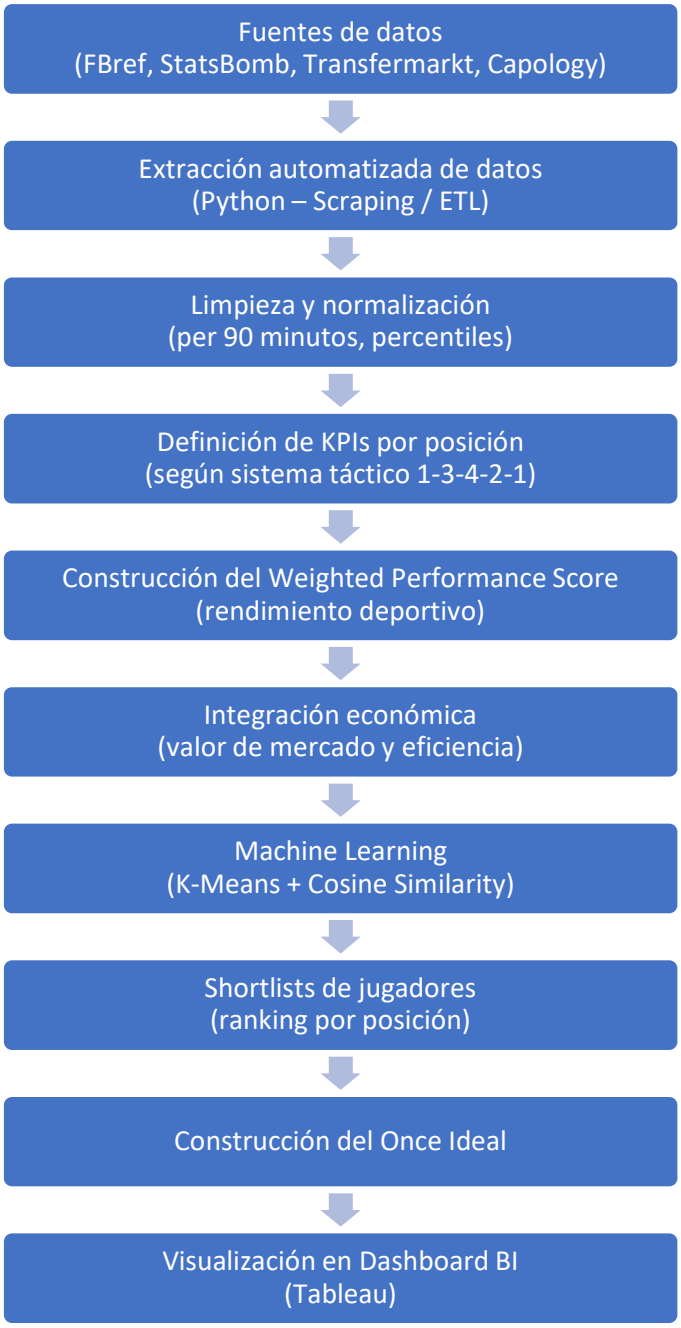

Flujo de trabajo del modelo de scouting data-driven desarrollado en el proyecto.

4. METODOLOGÍA APLICADA: MODELO CRISP-DM

El desarrollo del presente Trabajo Fin de Máster se estructura bajo el marco metodológico **CRISP-DM (Cross Industry Standard Process for Data Mining)**, ampliamente utilizado en proyectos de Ciencia de Datos por su carácter sistemático, iterativo y orientado a negocio.
La elección de este modelo responde a la necesidad de garantizar coherencia entre los objetivos estratégicos del club simulado y las técnicas analíticas empleadas, asegurando que cada fase del proyecto esté alineada con la toma de decisiones en la Dirección Deportiva.
CRISP-DM se compone de seis fases principales, que han sido adaptadas al contexto específico del scouting deportivo.

4.1. Comprensión del negocio

La primera fase del modelo se centra en definir con precisión el problema estratégico.
En este proyecto, el objetivo no es simplemente identificar "los mejores jugadores", sino construir un once titular competitivo en la Premier League bajo restricciones tácticas, económicas y estructurales previamente definidas.
Las variables estratégicas que condicionan el problema son:

- Presupuesto máximo de 350 millones de euros.
- Sistema táctico 1-3-4-2-1.
- Edad máxima de 30 años.
- Inclusión obligatoria de al menos dos jugadores Sub-21.
- Priorización de oportunidades de mercado (agentes libres e infravalorados).

Por tanto, el problema se redefine como:
Optimizar la asignación de recursos económicos para maximizar el rendimiento deportivo dentro de un sistema táctico específico.
Esta reformulación es clave, ya que transforma un problema deportivo en un problema de optimización bajo restricciones.

4.2. Comprensión de los datos

Una vez definido el problema, se procede a analizar la naturaleza y calidad de los datos disponibles.
El dataset maestro multi-liga incluye:

- Más de 200 variables iniciales por jugador.
- Métricas estándar y avanzadas.
- Información económica y contractual.

Durante esta fase se identificaron:

- Variables redundantes.
- Columnas completamente vacías.
- Diferencias estructurales entre tablas por posición.
- Necesidad de estandarización de métricas.

Se realizó un análisis exploratorio preliminar para:

- Estudiar distribuciones.
- Detectar valores extremos.
- Evaluar proporciones de datos faltantes.
- Analizar correlaciones entre métricas.

Esta etapa permitió depurar el dataset y preparar el terreno para la transformación analítica posterior.

4.3. Preparación y transformación de los datos

La fase de preparación constituye el núcleo técnico del proyecto.
Se llevaron a cabo los siguientes procesos:

4.3.1. Normalización per 90 minutos

Dado que los jugadores presentan diferentes volúmenes de minutos disputados, se estandarizaron las métricas ofensivas y defensivas en valores por 90 minutos.
Este procedimiento permite comparar jugadores en igualdad de condiciones.

4.3.2. Estandarización estadística

Para evitar que métricas con escalas diferentes dominen el modelo, se aplicaron transformaciones estadísticas:

- Percentiles (0–100).
- Ajustes por competitividad de liga.
- Reescalado de variables económicas.

Este paso es fundamental para garantizar equilibrio en el cálculo de índices sintéticos.

4.3.3. Filtrado estructural

Se aplicaron filtros de elegibilidad:

- Edad ≤ 30 años.
- Mínimo de minutos disputados.
- Exclusión de registros con valor de mercado no definido (salvo agentes libres estratégicos).

Este filtrado reduce ruido y aumenta la calidad del universo analizado.

4.4. Modelado

El modelado aplicado en el proyecto se estructura en dos niveles:

4.4.1. Segmentación de perfiles (Clustering)

Se utiliza el algoritmo K-Means para identificar agrupaciones naturales de jugadores según su estilo de juego real, independientemente de su posición nominal.

Este enfoque permite:

- Detectar perfiles híbridos.
- Identificar similitudes estructurales.
- Reducir sesgos posicionales tradicionales.

4.4.2. Búsqueda de similitudes y reemplazos

Mediante la aplicación de la similitud del coseno, se construyen sistemas de búsqueda de "jugadores equivalentes", permitiendo identificar:

- Sustitutos funcionales.
- Alternativas de menor coste.
- Perfiles jóvenes con métricas comparables a jugadores consolidados.

4.5. Evaluación

La evaluación del modelo no se limita a métricas matemáticas, sino que incorpora validación estratégica.

Se analizaron:

- Coherencia táctica de los perfiles seleccionados.
- Balance presupuestario final.
- Edad media de la plantilla.
- Proporción de talento Sub-21.
- Distribución del gasto por líneas.

Además, en el clustering se utilizaron métricas como:

- Método del codo (Elbow Method).
- Silhouette Score.

4.6. Despliegue

La fase final del modelo consiste en la transformación del análisis en una herramienta operativa.

Para ello se desarrolló un dashboard interactivo en Tableau que permite:

- Filtrar jugadores por posición.
- Visualizar rendimiento vs coste.
- Simular escenarios presupuestarios.
- Comparar perfiles tácticos.

Este despliegue convierte el modelo en un sistema replicable y utilizable por una Dirección Deportiva real

5. DESARROLLO TÉCNICO DEL MODELO: INGENIERÍA DE DATOS Y MACHINE LEARNING APLICADO

El presente capítulo constituye el núcleo técnico del proyecto. En él se integran los procesos de Ingeniería de Datos, construcción de métricas sintéticas y aplicación de técnicas de Machine Learning no supervisado, configurando un pipeline analítico completo orientado a la toma de decisiones en Dirección Deportiva.
El objetivo no es únicamente transformar datos estadísticos en información estructurada, sino diseñar un sistema cuantitativo capaz de:

- Traducir el modelo táctico 1-3-4-2-1 en variables medibles.
- Evaluar rendimiento deportivo relativo.
- Integrar dimensión económica y contractual.
- Detectar perfiles estructurales mediante segmentación estadística.
- Identificar sustituciones funcionales en el mercado.

Sobre esta base conceptual, el modelo desarrollado en este trabajo integra técnicas de ingeniería de datos, análisis estadístico y aprendizaje automático para apoyar la toma de decisiones en el proceso de scouting. A partir de datos de rendimiento deportivo y contexto económico obtenidos de fuentes abiertas, se construye un dataset maestro que posteriormente es normalizado mediante métricas por 90 minutos y percentiles estadísticos. Sobre esta base se definen indicadores clave de rendimiento (KPIs) específicos por posición dentro del sistema táctico 1-3-4-2-1. Estos KPIs se combinan en un índice sintético de rendimiento que posteriormente se complementa con información económica para generar un score final de evaluación. Finalmente, se aplican técnicas de Machine Learning no supervisado, como clustering y similitud del coseno, para identificar perfiles de jugadores comparables y detectar oportunidades de mercado que permitan construir un once titular competitivo dentro de las restricciones definidas en el proyecto.

5.1. Proceso ETL en Python y Construcción del Dataset Maestro

El desarrollo técnico se inicia con la construcción de un dataset maestro multi-liga mediante un proceso ETL (Extract, Transform, Load) implementado íntegramente en Python

5.1.1. Extracción automatizada

Se realizó la extracción automatizada de estadísticas estándar y avanzadas desde plataformas especializadas, principalmente FBref.
El procedimiento incluyó:

- Estadísticas estándar de jugadores de campo.
- Estadísticas específicas de porteros.
- Tablas avanzadas (shooting, passing, defense, possession, gca, etc.).

Dado que algunas tablas se encuentran embebidas en comentarios HTML, fue necesario implementar técnicas específicas de parsing utilizando herramientas de análisis estructural y automatización de navegación.

La automatización permitió consolidar información de siete competiciones europeas, generando un universo inicial superior a 900 jugadores.

5.1.2. Transformación y limpieza

Durante la fase de transformación se aplicaron los siguientes procesos:

- Conversión robusta a formato numérico.
- Eliminación de columnas completamente vacías.
- Normalización de nombres para facilitar integraciones.
- Eliminación de duplicidades mediante clave compuesta:
  Player + Squad + League + Season

Se aplicaron además filtros estructurales de elegibilidad:

- Edad ≤ 30 años.
- Mínimo de minutos disputados.
- Exclusión de registros inconsistentes.

Este filtrado reduce ruido estadístico y garantiza coherencia competitiva.

5.2. Normalización Estadística y Ajuste por Liga

Para garantizar comparabilidad entre jugadores y ligas, se aplicaron tres procesos fundamentales.

5.2.1. Normalización per 90 minutos

Las métricas acumuladas fueron transformadas a valores por 90 minutos con el fin de eliminar el sesgo derivado del volumen de minutos disputados.

Este procedimiento permite comparar titulares habituales con jugadores rotacionales o jóvenes emergentes en igualdad de condiciones.

5.2.2. Estandarización mediante percentiles

Las métricas fueron transformadas a percentiles (0–100) dentro de su universo posicional comparable.

Este enfoque permite:

- Identificar rendimiento relativo.
- Detectar outliers positivos.
- Comparar jugadores de distintas ligas bajo un mismo rango normalizado.

5.2.3. Ajuste por competitividad de liga

Se incorporó un factor de ajuste que pondera el rendimiento según el nivel competitivo de la liga de origen.

Este ajuste reduce sesgos estructurales y mejora la comparabilidad interliga, especialmente relevante al integrar competiciones con diferentes contextos competitivos.

5.3. Definición de KPIs por Posición

El sistema táctico 1-3-4-2-1 fue traducido a indicadores cuantificables específicos por rol.

Cada posición fue modelada mediante un conjunto estructurado de KPIs que reflejan sus funciones dentro del sistema.

Centrales con toque

- Intercepciones
- Duelo aéreo
- Pases progresivos
- Participación en salida de balón

Carrileros profundos

- Centros por 90
- Acciones progresivas
- Pases al área
- Recuperaciones tras pérdida

Mediocentros todocampistas

- Recuperaciones
- Intercepciones
- Pases progresivos
- Participación en construcción

Mediapuntas interiores

- xA por 90
- Pases clave
- Acciones creadoras de gol
- Conducciones progresivas

Delantero móvil

- xG por 90
- Participación en creación
- Presión tras pérdida
- Movilidad asociativa

Esta traducción del modelo táctico a métricas cuantificables constituye el puente entre la teoría futbolística y el análisis estadístico.

5.4. Construcción del Weighted Performance Score

Con el objetivo de sintetizar múltiples métricas en un único indicador interpretable, se diseñó un índice compuesto denominado **Weighted Performance Score**.

La fórmula general puede representarse como:

$$\text{Score_posición} = \sum (KPI_i \times Peso_i)$$

Donde:

- Cada KPI se encuentra previamente normalizado.
- Los pesos reflejan la relevancia estratégica dentro del sistema 1-3-4-2-1.

Este score permite evaluar rendimiento puro por posición, antes de incorporar dimensión económica.

5.5. Integración Económica y Score Final

Para dotar al modelo de aplicabilidad real, el rendimiento deportivo no se analiza de forma aislada.

Se incorporó una dimensión económica basada en:

- Valor de mercado (M€).
- Situación contractual.
- Métrica de eficiencia relativa (p_Efficiency).

Se construyó un **Score_Final** que integra rendimiento y coste, permitiendo detectar:

- Perfiles infravalorados.
- Agentes libres estratégicos.
- Activos con alto retorno potencial.

El modelo deja de responder únicamente a la pregunta "quién es mejor" y pasa a responder "quién ofrece mejor rendimiento por unidad de inversión".

5.6. Segmentación de Perfiles mediante Clustering (K-Means)

Con el objetivo de identificar estructuras latentes en los datos, se aplicó el algoritmo K-Means de forma independiente por posición modelo.

Justificación del algoritmo

K-Means fue seleccionado por:

- Su interpretabilidad.
- Su eficiencia computacional.
- Su coherencia con datasets estructurados y normalizados.
- Su escalabilidad a futuras temporadas.

El objetivo del clustering no es clasificar jugadores por nivel, sino detectar:

- Subtipos dentro de una misma posición.
- Perfiles híbridos.
- Diferencias estructurales de estilo de juego.

Determinación del número óptimo de clusters

Se realizó un escaneo de valores de k entre 2 y 10 evaluando:

- Inercia (Within Cluster Sum of Squares).
- Silhouette Score (medida de cohesión y separación).

El valor seleccionado corresponde al que maximiza el Silhouette Score manteniendo interpretabilidad táctica.

Interpretación táctica

Una vez entrenado el modelo, se calcularon las medias de las variables utilizadas dentro de cada cluster, permitiendo describir perfiles como:

- Perfil de alto impacto defensivo.
- Perfil creativo dominante.
- Perfil mixto equilibrado.

El clustering añade una capa estructural que complementa el sistema de scoring determinista.

5.7. Similitud del Coseno y Búsqueda de Reemplazos

Se implementó un modelo de recomendación basado en **Cosine Similarity** para identificar jugadores con estructura estadística similar a un objetivo de referencia.

La similitud se define como:

$$\mathrm{Sim}(A, B) = \frac{A \cdot B}{||A|| \times ||B||}$$

Este procedimiento permite:

- Identificar "clones estadísticos".
- Detectar alternativas de menor coste.
- Validar sustituciones funcionales frente a referencias élite.

La similitud se expresa como porcentaje para facilitar interpretación estratégica.

5.8. Modelo de Detección Sub-21

El escenario simulado exige la incorporación obligatoria de al menos dos jugadores Sub-21 en el once titular.

Para ello, se implementó un filtro específico que:

- Identifica jugadores ≤ 21 años.
- Evalúa su rendimiento relativo dentro del universo elegible.
- Permite compararlos mediante percentiles en igualdad de condiciones.

Este bloque permite integrar juventud sin comprometer competitividad inmediata.

5.9. Exportación y Trazabilidad

Como salida final del bloque técnico, se generaron archivos consolidados que incluyen:

- Dataset final para BI.
- Asignación de clusters por posición.
- Resultados del escaneo de k.
- Perfiles medios por cluster.

Esto garantiza:

- Reproducibilidad.
- Transparencia metodológica.
- Trazabilidad completa entre análisis y resultados.

6. DESARROLLO DE LA HERRAMIENTA BI

El proceso analítico desarrollado en los capítulos anteriores culmina en la construcción de una herramienta de visualización interactiva orientada a la toma de decisiones estratégicas en Dirección Deportiva.

El objetivo de esta herramienta no es únicamente representar datos, sino transformar el modelo cuantitativo desarrollado en un sistema operativo capaz de:

- Comparar rendimiento y coste.
- Validar restricciones presupuestarias.
- Analizar estructura generacional.
- Simular escenarios de planificación de plantilla.

Para ello, se utilizó **Tableau Desktop Public Edition**, herramienta que permite la construcción de dashboards interactivos a partir del dataset final generado en Python.

6.1. Diseño del Dashboard

El diseño de la herramienta se planteó bajo un principio fundamental: claridad estratégica.
El usuario objetivo del dashboard es un Director Deportivo que necesita:

- Información sintetizada.
- Comparaciones visuales inmediatas.
- Capacidad de filtrado dinámico.
- Validación rápida de restricciones.

Se evitaron visualizaciones innecesarias y se priorizaron gráficos de alto impacto interpretativo.
El diseño se estructuró en dos dashboards principales:

1. Dashboard de Análisis Coste–Rendimiento.
2. Dashboard de Planificación Estratégica del Once Ideal.

Ambos se alimentan del dataset consolidado exportado desde Python, que incluye:

- Score_Rendimiento
- Score_Final
- Valor_M€
- p_Efficiency
- Opportunity_Score
- Indicador Sub-21
- Indicador Once_Ideal
- Posición táctica (Pos_Model)

6.2. Estructura de la interfaz

La interfaz fue diseñada siguiendo una lógica jerárquica de análisis:
Nivel 1 — Universo completo de mercado
Permite analizar todos los jugadores elegibles bajo las restricciones del modelo (edad ≤ 30, minutos mínimos, etc.).
Incluye filtros dinámicos por:

- Posición táctica.
- Liga.
- Sub-21.
- Situación contractual.

Nivel 2 — Once Ideal seleccionado
Permite aislar exclusivamente los jugadores elegidos en la propuesta final de plantilla.
Se incorporaron campos específicos como:

- Pos_XI (posición dentro del once).
- Coste_Fichaje_Unico (para evitar duplicidades).
- Once_Ideal (variable booleana).

Esta separación conceptual permite diferenciar claramente entre análisis de mercado y planificación final.

6.3. Visualizaciones clave

6.3.1. Dashboard 1 — Análisis Coste–Rendimiento

Este dashboard responde a la pregunta estratégica:
¿Qué jugadores ofrecen mayor rendimiento relativo por menor coste?
Incluye dos visualizaciones principales:
Scatter Plot: Valor de Mercado vs Score Final

- Eje X → Valor_M€
- Eje Y → Score_Final
- Color → Liga
- Tooltip → Player, Squad, Age, Sub-21, Opportunity_Score

Este gráfico permite identificar:

- Jugadores de alto rendimiento y bajo coste.
- Perfiles sobrevalorados.
- Oportunidades de mercado.

El análisis visual facilita la detección de ineficiencias de mercado, alineándose con el objetivo estratégico del proyecto.
Distribución de rendimiento por posición (Boxplot)

- Eje X → Pos_Model
- Eje Y → Score_Final

Esta visualización permite validar que el modelo discrimina correctamente entre perfiles y no concentra artificialmente el rendimiento en una única línea.
Sirve como mecanismo de control interno del modelo cuantitativo.

6.3.2. Dashboard 2 — Planificación Estratégica del Once Ideal

Este dashboard traslada el análisis al escenario práctico final.
Responde a la pregunta:
¿Es coherente, equilibrado y sostenible el once seleccionado?
Incluye tres visualizaciones principales:
1. Valor del XI por Línea

Gráfico de barras que muestra el valor agregado por:

- Portería
- Defensa
- Carrileros
- Mediocampo
- Mediapuntas
- Delantero

Se utiliza el campo Coste_Fichaje_Unico para evitar duplicidades derivadas de jugadores con múltiples posiciones.
Este gráfico permite validar la distribución presupuestaria por líneas.
2. Estructura generacional del XI

Gráfico de barras ordenado por edad que distingue:

- Sub-21
- No Sub-21

Permite comprobar:

- Cumplimiento de la cuota obligatoria.

- Equilibrio entre juventud y experiencia.
- Sostenibilidad a medio plazo.

3. Tabla resumen del Once Ideal

Incluye:

- Player
- Posición en el XI
- Edad
- Score_Final
- Valor_M€
- Opportunity_Score

Sirve como síntesis ejecutiva del modelo final.

6.4. Simulación de escenarios

La herramienta desarrollada no es estática.
Gracias al uso de filtros dinámicos, permite:

- Sustituir jugadores.
- Evaluar impacto presupuestario inmediato.
- Comparar alternativas.
- Analizar efectos en la media de edad.
- Detectar desequilibrios en la estructura de coste.

Este componente convierte el dashboard en una herramienta replicable y aplicable a contextos reales de Dirección Deportiva.

6.5. Síntesis operativa de la herramienta

La herramienta desarrollada transforma el modelo cuantitativo en un sistema operativo de toma de decisiones.

Permite analizar rendimiento, coste, estructura generacional y distribución presupuestaria bajo un entorno interactivo.

De este modo, el análisis deja de ser meramente descriptivo para convertirse en un instrumento estratégico aplicable a la planificación real de plantilla.

7. CASO PRÁCTICO: CONSTRUCCIÓN DEL ONCE IDEAL

El presente capítulo constituye la aplicación práctica del modelo desarrollado en los bloques anteriores. Tras la construcción del dataset maestro, la definición de KPIs específicos por posición y la implementación de técnicas de Machine Learning, se procede a la selección del once titular bajo las restricciones estratégicas previamente definidas.

El objetivo no es simplemente proponer “los mejores jugadores”, sino construir un once coherente con:

- El sistema táctico 1-3-4-2-1.
- El presupuesto máximo de 350 millones de euros.
- La restricción de edad ≤ 30 años.
- La incorporación obligatoria de al menos dos jugadores Sub-21.
- La priorización de perfiles eficientes o infravalorados.

La selección final responde, por tanto, a un equilibrio entre rendimiento, encaje táctico y viabilidad económica.

7.1. Estrategia presupuestaria

Antes de la selección individual, se estableció una distribución estratégica del presupuesto por líneas, alineada con el modelo de juego.

Dado que el sistema 1-3-4-2-1 otorga gran protagonismo a:

- Carrileros profundos.
- Doble pivote estructural.
- Mediapuntas interiores dinámicos.

Se decidió priorizar inversión en:

- Eje defensivo central.
- Mediocentro organizador.
- Zona ofensiva diferencial.

La asignación presupuestaria resultante mantiene equilibrio entre:

- Solidez estructural.
- Capacidad ofensiva.
- Sostenibilidad económica.

El coste total del once seleccionado se mantiene dentro del límite de 350M€, cumpliendo estrictamente la restricción establecida.

7.2. Selección por Líneas

7.2.1. Portería

Player	Squad	League	Age	Pos	Valor	Score_Final
Robin Risser	Lens	Ligue 1	21	GK	10.0	81964261
Hervé Koffi	Angers	Ligue 1	29	GK	3.0	81671932
Marco Carnesecchi	Atalanta	Serie A	25	GK	25.0	81511932
Joan García	Barcelona	La Liga	24	GK	30.0	80178295
Mile Svilar	Roma	Serie A	26	GK	35.0	79584375
Ionuț Radu	Celta Vigo	La Liga	28	GK	5.0	78383182
Dominik Greif	Lyon	Ligue 1	28	GK	8.0	75549545
Daniel Iversen	Preston North End	Championship	28	GK	2.5	73374716
Vanja Milinković-Savić	Napoli	Serie A	29	GK	25.0	70736364
Viktor Johansson	Stoke City	Championship	27	GK	10.0	65046591

Joan García
El perfil seleccionado destaca por:

- Alto rendimiento en métricas de ShotStopping.
- Buen posicionamiento en percentiles dentro del universo elegible.
- Edad óptima (perfil proyectable).
- Coste contenido en relación rendimiento-precio.

Aunque el ranking presenta perfiles con puntuaciones ligeramente superiores, **Joan García** ofrece una combinación más equilibrada entre rendimiento, edad y potencial de desarrollo. El modelo lo sitúa en el **cluster de porteros de alto impacto**, validando su encaje competitivo dentro del proyecto.

7.2.2. Línea de Tres Centrales

Ranking del modelo para centrales

Player	Squad	League	Age	Valor€	Fin_Contrato	Score_Final
Marcos Senesi	Bournemouth	Premier League	28	22.0	Sí	96869565
Malang Sarr	Lens	Ligue 1	27	10.0	Sí	96739130
Danilho Doekhi	Union Berlin	Bundesliga	27	13.0	Sí	96347826
Oumar Solet	Udinese	Serie A	26	20.0	No	91034783
David Affengruber	Elche	La Liga	24	9.0	No	90766522
Maxence Lacroix	Crystal Palace	Premier League	25	35.0	No	90173913
Ibrahima Konaté	Liverpool	Premier League	26	50.0	Sí	87136957
Tiago Gabriel	Lecce	Serie A	21	15.0	No	86200000
Ben Cabango	Swansea City	Championship	25	9.0	No	85525000
Saúl Coco	Torino	Serie A	27	18.0	No	81404891

Selección final:

Marcos Senesi – Ibrahima Konaté – Maxence Lacroix

El sistema **1-3-4-2-1** exige centrales capaces de:

- Defender amplitud.
- Participar en salida de balón.
- Cubrir grandes espacios en transición.

Marcos Senesi aporta el perfil de central zurdo con capacidad de progresión y buena distribución desde el primer pase, facilitando la salida de balón por el lado izquierdo. Además, su **situación contractual próxima a finalización** lo convierte en una oportunidad estratégica de mercado dentro del modelo económico del proyecto.

Ibrahima Konaté proporciona el anclaje físico de la línea defensiva, destacando en duelos aéreos, capacidad de corrección y dominio en situaciones de defensa del área. Su **finalización de contrato en el corto plazo** refuerza su atractivo desde el punto de vista

estratégico, permitiendo incorporar un perfil de élite bajo condiciones potencialmente favorables.

Maxence Lacroix añade velocidad correctora y capacidad para defender espacios largos, un atributo clave en sistemas con línea de tres centrales que deben gestionar amplias zonas defensivas.

Desde el punto de vista cuantitativo, los tres jugadores:

- Se ubican en **clusters defensivos de alto impacto estructural**.
- Presentan percentiles elevados en métricas defensivas clave.
- Mantienen un equilibrio adecuado entre rendimiento y coste.

La combinación de estos perfiles genera una línea defensiva **complementaria y coherente con los resultados del modelo estadístico**.

7.2.3. Carrileros

Player	Squad	League	Age	Pie	Valor	Score_Final
Harry Wilson	Fulham	Premier League	28	Left	20.0	94041282
Marcos Senesi	Bournemouth	Premier League	28	Left	22.0	89311450
Ryan Sessegnon	Fulham	Premier League	25	Left	20.0	87385399
David Raum	RB Leipzig	Bundesliga	27	Left	20.0	85153277
Carlos Romero	Espanyol	La Liga	24	Left	15.0	83741443
Zeki Çelik	Roma	Serie A	29	Right	12.0	81962768
Weston McKennie	Juventus	Serie A	27	Right	22.0	81768072
Tommy Doyle	Birmingham City	Championship	24	Right	8.0	81359627
Reece James	Chelsea	Premier League	26	Right	50.0	79345938
Jordan Holsgrove	Estoril	Primeira Liga	26	Left	3.5	79344426

David Raum – Patrick Dorgu

El sistema exige carrileros con funciones ofensivas similares a las de un extremo.

David Raum destaca por:

- Elevado volumen de centros por 90 minutos.
- Alta participación en acciones progresivas.
- Producción ofensiva constante.

Patrick Dorgu, además de cumplir el requisito **Sub-21**, aporta:

- Proyección física y capacidad de recorrido.
- Alto potencial de revalorización.
- Intensidad competitiva acorde a la exigencia de la Premier League.

Ambos perfiles se sitúan dentro del **cluster de carrileros de alta producción ofensiva**, validando su encaje en el modelo.

7.2.4. Doble Mediocentro

Player	Squad	League	Age	Valor	Fin_Contrato	Score_Final
Mateus Fernandes	West Ham United	Premier League	21	32.0	No	82364679
Weston McKennie	Juventus	Serie A	27	22.0	Sí	81892500
Jon Gorrotxategi	Real Sociedad	La Liga	24	15.0	No	76205183
Tim Iroegbunam	Everton	Premier League	22	12.0	No	75089450
Antonio Blanco	Alavés	La Liga	25	10.0	No	73813945
Arthur Avom	Lorient	Ligue 1	21	9.0	Sí	68495732
Nico O'Reilly	Manchester City	Premier League	20	40.0	No	68167431
Nicolas Seiwald	RB Leipzig	Bundesliga	24	18.0	No	67978349
Taichi Fukui	Arouca	Primeira Liga	21	2.0	No	67840367
Tajon Buchanan	Villarreal	La Liga	27	10.0	No	67401972

Mateus Fernandes – Martín Zubimendi
El sistema requiere equilibrio entre destrucción y creación.

Martín Zubimendi representa el eje organizador del equipo:

- Alto **Creator_Index**.
- Participación constante en la construcción del juego.
- Gran coherencia posicional dentro del sistema.

El análisis de similitud lo sitúa próximo a perfiles de referencia en el fútbol de élite.

Mateus Fernandes aporta:

- Capacidad de recuperación y presión.
- Transición vertical tras recuperación.
- Proyección física acorde a la exigencia de la liga.

Además, su **situación contractual cercana a finalización** representa una oportunidad estratégica de mercado que refuerza su encaje dentro de la planificación económica del proyecto.

7.2.5. Mediapuntas Interiores

Player	Squad	League	Age	Valor	Fin_Contrato	Score_Final
Julian Brandt	Dortmund	Bundesliga	29	25.0	Sí	87405176
Deniz Undav	Stuttgart	Bundesliga	29	20.0	No	86943529
Chris Führich	Stuttgart	Bundesliga	28	15.0	No	81592941

Marcus Rashford	Barcelona	La Liga	28	40.0	No	81308382
Abde Ezzalzouli	Real Betis	La Liga	24	25.0	No	79516324
Antony	Real Betis	La Liga	26	30.0	No	78472059
Said El Mala	Köln	Bundesliga	19	40.0	No	77392941
Brandon Thomas-Asante	Coventry City	Championship	27	12.0	No	76347794
Léo Scienza	Southampton	Championship	27	9.0	No	75106985
Raphinha	Barcelona	La Liga	29	80.0	No	74922059

Marcus Rashford – Said El Mala

El modelo prioriza perfiles con creatividad, movilidad y amenaza ofensiva.

Marcus Rashford aporta:

- Alto **GoalThreat_Index**.
- Experiencia competitiva en contextos de máximo nivel.
- Capacidad de ruptura y amenaza al espacio.

Aunque el ranking incluye perfiles con puntuación ligeramente superior, Rashford aporta un **impacto ofensivo diferencial** dentro del sistema.

Said El Mala, perfil **Sub-21**, ofrece:

- Elevado **Creator_Index relativo**.
- Alto potencial de desarrollo.
- Coste contenido frente a su producción ofensiva.

El análisis de similitud lo aproxima a perfiles consolidados, validando su elección como talento proyectable.

7.2.6. Delantero Centro

Player	Squad	League	Age	Valor	Fin_Contrato	Score_Final
Nikola Krstović	Atalanta	Serie A	25	20.0	No	88599113
Jonathan Burkardt	Eintracht Frankfurt	Bundesliga	25	35.0	No	85883404
Igor Matanovic	Freiburg	Bundesliga	22	7.0	No	83838298
Ellis Simms	Coventry City	Championship	25	8.0	No	83178546
Vangelis Pavlidis	Benfica	Primeira Liga	27	35.0	No	80026950
Gianluca Scamacca	Atalanta	Serie A	27	25.0	No	78703457
Christian Pulisic	Milan	Serie A	27	65.0	No	78018794
Lautaro Martínez	Inter	Serie A	28	85.0	No	76390248
Marcus Thuram	Inter	Serie A	28	65.0	No	71023582
Haji Wright	Coventry City	Championship	27	12.0	No	69858067

Vangelis Pavlidis

El delantero seleccionado destaca por:

- Alto **GoalThreat_Index**.
- Relación rendimiento-coste favorable.
- Perfil asociativo compatible con el sistema.

Aunque el ranking incluye delanteros con mayor puntuación absoluta, **Pavlidis presenta una combinación más eficiente entre producción ofensiva y coste de mercado**, manteniendo métricas competitivas dentro del universo analizado.

El análisis de similitud lo aproxima estructuralmente a delanteros de élite, ofreciendo una alternativa **económicamente más eficiente** dentro del modelo desarrollado.

7.3. Integración de talento Sub-21

El escenario estratégico del proyecto establece como requisito obligatorio la incorporación de, al menos, dos jugadores Sub-21 en el once titular. Esta restricción no debe entenderse como una imposición aislada, sino como una política de gestión de activos orientada a:

- Garantizar proyección futura.
- Asegurar potencial de revalorización.
- Reducir riesgo financiero estructural.
- Construir sostenibilidad competitiva a medio plazo.

El once propuesto no solo cumple dicha condición, sino que la supera estratégicamente al incorporar tres perfiles Sub-21:

- **Patrick Dorgu (Carrilero derecho)**
- **Said El Mala (Mediapunta interior)**
- **Mateus Fernandes (Mediocentro)**

Validación cuantitativa

La selección de estos perfiles no responde exclusivamente a su edad, sino a su posicionamiento competitivo dentro del universo estadístico analizado.

- Dorgu se sitúa en el cluster ofensivo de carrileros de alta producción.
- Said El Mala presenta percentiles elevados en métricas de creatividad y amenaza ofensiva relativa.
- Mateus Fernandes combina métricas de recuperación y progresión, mostrando equilibrio entre Destroyer_Index y Creator_Index dentro de su grupo posicional.

El análisis de percentiles demuestra que su rendimiento relativo es competitivo frente a jugadores de mayor experiencia.

Impacto estratégico

La inclusión de tres Sub-21 genera varios efectos positivos en el modelo:

1. Reduce la edad media del once sin comprometer el rendimiento.
2. Aumenta el potencial de revalorización futura del activo deportivo.

3. Mejora la sostenibilidad financiera del proyecto.
4. Refuerza la identidad de proyecto joven alineado con inversión inteligente.

Además, al distribuir el talento joven en diferentes líneas (defensa, mediocampo y ataque), se evita concentrar el riesgo en una única zona del campo.

Equilibrio generacional

El once resultante combina:

- Núcleo estructural en edad competitiva óptima (24–28 años).
- Talento joven proyectable.
- Jugadores consolidados en posiciones clave.

Esta configuración responde a un modelo de plantilla equilibrado, competitivo a corto plazo y sostenible a medio plazo.

7.4. Auditoría económica

Una vez definido el once titular a partir del modelo de evaluación, se procede a analizar la **viabilidad económica de la plantilla resultante**, verificando su compatibilidad con el presupuesto establecido en el escenario del proyecto.

El coste total del once seleccionado:

- Se mantiene dentro del límite de **350 millones de euros** establecido como restricción del modelo.
- Presenta una **distribución equilibrada de la inversión entre las distintas líneas del equipo**.
- Evita una concentración excesiva del gasto en una única posición, favoreciendo la sostenibilidad de la planificación deportiva.

Además, el modelo identifica **oportunidades estratégicas de mercado asociadas a jugadores con contrato cercano a su finalización**, lo que permitiría incorporar determinados perfiles **a coste de traspaso reducido o incluso como agentes libres**. Esta circunstancia afecta a varios jugadores seleccionados en el once, reforzando la viabilidad económica de la propuesta.

Las métricas **p_Efficiency** y **Opportunity_Score** permiten justificar económicamente las decisiones del modelo, identificando jugadores con **alto rendimiento relativo en relación con su coste de mercado** y detectando **situaciones contractuales favorables** dentro del mercado analizado.

En conjunto, el modelo demuestra que es posible construir una plantilla **competitiva desde el punto de vista deportivo y coherente con las restricciones económicas definidas en el proyecto**, optimizando simultáneamente rendimiento, coste y oportunidades de mercado.

Posición	Jugador	Valor M€	Fin Contrato
GK	Joan García	30	No
DFI	Senesi	22	Sí
DFC	Konaté	50	Sí
DFD	Lacroix	35	No
CAI	Raum	20	No
CAD	Dorgu	30	No
MC	Zubimendi	75	No
MC	Mateus Fernandes	32	Sí
MPI	Rashford	40	No
MPD	El Mala	40	No
DC	Pavlidis	35	No

7.5. Análisis de edad media

La edad media del once se sitúa en un rango competitivo óptimo para Premier League:

- Equilibrio entre experiencia y proyección.
- Potencial de revalorización futura.
- Sostenibilidad estructural a medio plazo.

La combinación de perfiles consolidados y talento emergente refuerza la viabilidad del proyecto deportivo.

8. DISCUSIÓN DE RESULTADOS

El presente capítulo tiene como objetivo analizar críticamente los resultados obtenidos tras la aplicación del modelo integral de **Scouting Data-Driven**. No se trata únicamente de reiterar métricas, sino de interpretar estratégicamente el impacto del sistema desarrollado y evaluar su coherencia respecto a los objetivos iniciales del proyecto.

8.1. Validación del modelo

La validación del modelo se realiza desde una triple dimensión: **táctica, económica y estructural**, permitiendo evaluar si el sistema desarrollado genera una solución coherente desde el punto de vista deportivo y estratégico.

Validación táctica

El once seleccionado presenta coherencia con el sistema **1-3-4-2-1** definido como marco estructural del proyecto.

- Los centrales seleccionados combinan capacidad defensiva y participación en salida de balón.
- Los carrileros presentan una producción ofensiva relativa elevada dentro de su universo posicional.
- El doble pivote equilibra funciones de creación y recuperación.
- Los mediapuntas aportan creatividad y amenaza ofensiva en el último tercio.
- El delantero combina movilidad, participación asociativa y producción goleadora.

Además, la aplicación de técnicas de **clustering por posición** permitió identificar subperfiles reales dentro de cada rol, confirmando que la selección no se basa únicamente en la posición nominal del jugador, sino en su **estructura estadística de rendimiento**.

La utilización de **similitud del coseno** permitió comprobar que varios de los jugadores seleccionados presentan cercanía estructural con perfiles de referencia dentro del fútbol europeo, reforzando la coherencia del modelo.

Validación económica

Desde el punto de vista económico, el modelo cumple estrictamente la restricción presupuestaria establecida de **350 millones de euros**.

La auditoría económica demuestra:

- distribución equilibrada del gasto entre líneas,
- ausencia de concentración excesiva de inversión en una única posición,
- identificación de perfiles con alta relación **rendimiento–coste**.

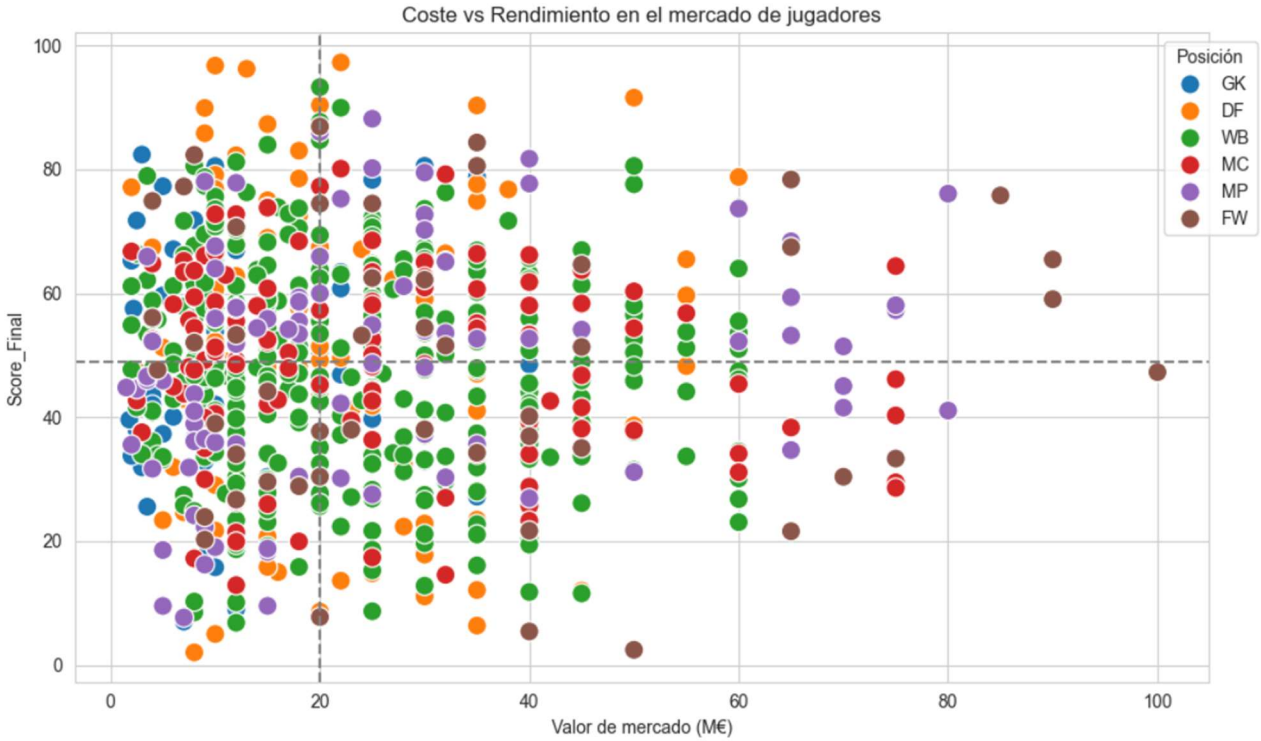

Para validar visualmente la coherencia económica del modelo se representa la relación entre el **valor de mercado de los jugadores** y el **rendimiento estimado mediante el indicador Score_Final.**

Relación entre valor de mercado (Valor_M€) y rendimiento estimado por el modelo (Score_Final).

El gráfico de dispersión permite observar cómo el modelo identifica jugadores con alto impacto deportivo independientemente de su coste de mercado. En particular, los jugadores situados en la zona superior izquierda representan perfiles con **alto rendimiento relativo y coste moderado**, considerados oportunidades estratégicas dentro del mercado.

La incorporación de métricas como **p_Efficiency** y **Opportunity_Score** permitió reforzar este análisis, facilitando la detección de oportunidades de mercado más allá del rendimiento absoluto.

Validación estructural y generacional

El once final integra **tres jugadores Sub-21**, superando el mínimo exigido por el escenario planteado.

Esto garantiza:

- sostenibilidad generacional de la plantilla,
- potencial de revalorización futura,
- reducción del riesgo estructural a medio plazo.

La edad media resultante se sitúa en un rango competitivo óptimo para la **Premier League**, equilibrando experiencia competitiva y proyección de crecimiento.

En conjunto, el modelo demuestra capacidad para **transformar restricciones complejas —tácticas, económicas y estructurales— en una solución integrada y coherente**, replicable en contextos reales de planificación deportiva

8.2. Fortalezas del modelo

El modelo desarrollado presenta diversas fortalezas estructurales:

1. **Integración rendimiento–economía**

El sistema no se limita a medir producción deportiva, sino que incorpora eficiencia económica y contexto contractual. Esto lo convierte en una herramienta potencialmente aplicable a procesos reales de **Dirección Deportiva**.

2. **Adaptación táctica específica**

El modelo no es genérico, sino que ha sido diseñado específicamente para un sistema **1-3-4-2-1**, traduciendo conceptos tácticos en **KPIs cuantificables**.

3. **Comparabilidad interliga**

El ajuste por competitividad de liga permite reducir sesgos estructurales y mejorar la evaluación transversal entre jugadores de diferentes competiciones.

4. **Reducción de subjetividad**

El filtrado inicial se realiza mediante métricas objetivas y técnicas de modelado no supervisado, reduciendo la dependencia de reputación mediática o percepciones subjetivas.

5. **Replicabilidad**

El sistema puede reproducirse temporada tras temporada, adaptándose a distintos presupuestos, ligas o modelos tácticos.

8.3. Limitaciones del estudio

A pesar de sus fortalezas, el modelo presenta ciertas limitaciones que deben reconocerse desde una perspectiva crítica.

1. **Ausencia de tracking data**

No se incorporan métricas espacio-temporales como:

- Distancias recorridas.
- Intensidad de presión.
- Mapas de ocupación espacial.

Estas variables enriquecerían la evaluación táctica.

2. **No se incluyen variables médicas o psicológicas**

El modelo no contempla:

- Historial de lesiones.
- Resiliencia competitiva.
- Liderazgo o adaptación cultural.

Factores relevantes en decisiones reales.

3. **Dependencia de valor de mercado estimado**

El valor de mercado utilizado es orientativo y puede no coincidir con el coste real de traspaso.

4. **Naturaleza no supervisada del clustering**

Los resultados del K-Means dependen de la selección de features y del número óptimo de clusters, lo que introduce cierto grado de sensibilidad metodológica.

Reconocer estas limitaciones refuerza la credibilidad académica del trabajo.

9. CONCLUSIONES Y LÍNEAS FUTURAS

Este capítulo sintetiza los aprendizajes estratégicos del proyecto y plantea posibles desarrollos futuros.

9.1. Conclusiones estratégicas

El presente Trabajo Fin de Máster demuestra que es posible estructurar un proceso de toma de decisiones en Dirección Deportiva mediante un enfoque integral Data-Driven.

El modelo desarrollado:

- Traduce un sistema táctico en métricas cuantificables.
- Integra rendimiento deportivo y eficiencia económica.
- Permite segmentar perfiles por estilo real de juego.
- Facilita la identificación de sustitutos funcionales.
- Genera un once titular competitivo bajo restricciones reales.

La principal aportación del proyecto no reside en la selección concreta de jugadores, sino en la construcción de un sistema replicable, escalable y defendible de toma de decisiones estratégicas.

Se demuestra que la profesionalización del scouting mediante Ciencia de Datos no sustituye la intuición, sino que la complementa y la estructura.

9.2. Integración de Tracking Data

Como evolución natural del modelo, se propone la integración de datos de tracking:

- Posicionamiento espacio-temporal.
- Intensidad de presión real.
- Coberturas defensivas.
- Patrones de ocupación en transición.

La incorporación de estos datos permitiría enriquecer los KPIs actuales con una dimensión dinámica del juego.

9.3. Inteligencia Artificial Generativa

Otra línea futura de gran potencial es la integración de IA generativa en el proceso de scouting.

Posibles aplicaciones:

- Generación automática de informes individuales personalizados.
- Simulación narrativa de escenarios de mercado.
- Asistentes tácticos que combinen datos y explicación contextual.
- Sistemas híbridos predictivos de evolución de rendimiento.

La combinación de análisis estructurado y modelos generativos puede transformar radicalmente la Dirección Deportiva en entornos de alta competencia.

10. BIBLIOGRAFÍA

Metodología y Ciencia de Datos

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step Data Mining Guide*. SPSS Inc.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning*. Springer.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An Introduction to Statistical Learning*. Springer.

Kuhn, M., & Johnson, K. (2013). *Applied Predictive Modeling*. Springer.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Modelos no supervisados y métricas de validación

MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, 281–297.

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics, 20*, 53–65.

Tan, P.-N., Steinbach, M., & Kumar, V. (2019). *Introduction to Data Mining* (2nd ed.). Pearson.

Análisis cuantitativo aplicado al fútbol

Anderson, C., & Sally, D. (2013). *The Numbers Game: Why Everything You Know About Football Is Wrong*. Penguin Books.
Doal Pérez Frías, E. (2022). *Métodos predictivos para fútbol y mercados de apuestas* (2ª ed.). Independently published.
Clemente, F. M., Couceiro, M. S., Martins, F. M. L., & Mendes, R. (2015). Using network metrics to investigate football team behaviour. *Journal of Sports Sciences, 33*(20), 219–230.

Fuentes de datos y herramientas tecnológicas

FBref. (2026). *Football statistics and advanced metrics database*. https://fbref.com
StatsBomb. (2026). *Advanced football data and metrics documentation*. https://statsbomb.com
Transfermarkt. (2026). *Market value and contract data*. https://transfermarkt.com
Tableau Software. (2026). *Tableau Desktop Public Edition Documentation*. https://tableau.com

Material docente del programa

Máster en Big Data aplicado al Scouting en Fútbol. (2025–2026). *Material docente interno de los módulos 1–10*. Sports Data Campus – UCAM.

11. ANEXOS

El presente Trabajo Fin de Máster incorpora un conjunto de materiales técnicos que garantizan la trazabilidad, reproducibilidad y transparencia metodológica del modelo integral de Scouting Data-Driven desarrollado.
Con el objetivo de mantener el cuerpo principal del documento enfocado en el análisis estratégico y metodológico, la implementación técnica completa se adjunta en una carpeta comprimida entregada junto al presente documento.
Dicha carpeta contiene los siguientes elementos:

11.1. Script completo en Python

Este archivo contiene la implementación íntegra del modelo desarrollado en el proyecto, estructurado en los siguientes bloques:

1. Construcción del Dataset Maestro
    - Configuración del entorno y rutas del proyecto.
    - Extracción automatizada multi-liga desde FBref.
    - Normalización estructural de tablas estándar y avanzadas.
    - Consolidación mediante clave compuesta (Player, Squad, League, Season).
    - Depuración de duplicados estructurales.
    - Integración económica (Valor_M€, Pie, Altura_cm).
    - Integración de situación contractual (fin_contrato).
2. Ingeniería de Datos por Posición
    - Normalización per 90 minutos.
    - Estandarización mediante percentiles.

- Ajuste por competitividad de liga (League Factor).
- Definición de KPIs específicos por rol táctico.
- Construcción del Weighted Performance Score.
- Integración económica (Score_Final, p_Efficiency, Opportunity_Score).
- Generación de shortlists defendibles por línea.

3. Exportación del Dataset Analítico
   - Preparación del dataset consolidado para Business Intelligence.
   - Generación de DATASET_DASHBOARD_TFM.xlsx.
4. Machine Learning Aplicado
   - Definición de features por posición.
   - Segmentación mediante K-Means.
   - Determinación del número óptimo de clusters (Elbow + Silhouette).
   - Perfilado de clusters.
   - Implementación de similitud del coseno para búsqueda de sustitutos.
   - Validación comparativa frente a referencias élite.
   - Exportación de resultados en ML_CAP4_OUTPUTS.xlsx.

El script ha sido desarrollado utilizando:

- pandas
- numpy
- scikit-learn
- BeautifulSoup
- SeleniumBase
- RapidFuzz
- matplotlib
- seaborn

11.2. Dataset final para Business Intelligence

Se adjunta el archivo:

DATASET_DASHBOARD_TFM.xlsx

Este archivo constituye la capa analítica final utilizada para el desarrollo del dashboard en Tableau e incluye:

- Score_Rendimiento
- Score_Final
- Valor_M€
- p_Efficiency
- Opportunity_Score
- Indicador Sub-21
- Indicador Once_Ideal
- Posición modelo (Pos_Model)
- Información contractual

Este dataset permite reproducir el análisis visual sin necesidad de ejecutar nuevamente el script completo.

11.3. Outputs del modelo de Machine Learning

Se adjunta el archivo:

ML_CAP4_OUTPUTS.xlsx

Contiene:

- Asignación de clusters por posición.
- Resultados del escaneo de k (inercia y Silhouette Score).
- Perfil medio de cada cluster.
- Resultados consolidados de segmentación estructural.

Este documento permite auditar el comportamiento interno del modelo no supervisado y validar la consistencia de los perfiles detectados.

11.4. Archivo del Dashboard Interactivo

Se adjunta el archivo:

Dashboard_TFM_PremierLeague.twbx

Este archivo contiene la herramienta de visualización desarrollada en Tableau Desktop. Incluye dos entornos principales:

Dashboard 1 — Análisis Coste–Rendimiento

- Scatter plot Valor_M€ vs Score_Final.
- Identificación de oportunidades de mercado.
- Filtros dinámicos por posición, liga y Sub-21.

Dashboard 2 — Planificación Estratégica del Once Ideal

- Distribución presupuestaria por líneas.
- Estructura generacional del XI.
- Tabla resumen ejecutiva del once seleccionado.
- Simulación de escenarios de sustitución.

El dashboard transforma el modelo cuantitativo en una herramienta operativa de toma de decisiones replicable en entornos reales de Dirección Deportiva.

Análisis Estratégico del Mercado: Coste-Rendimiento y validación por Rol Táctico

Análisis Coste-Rendimiento (Score Final vs Valor de Mercado

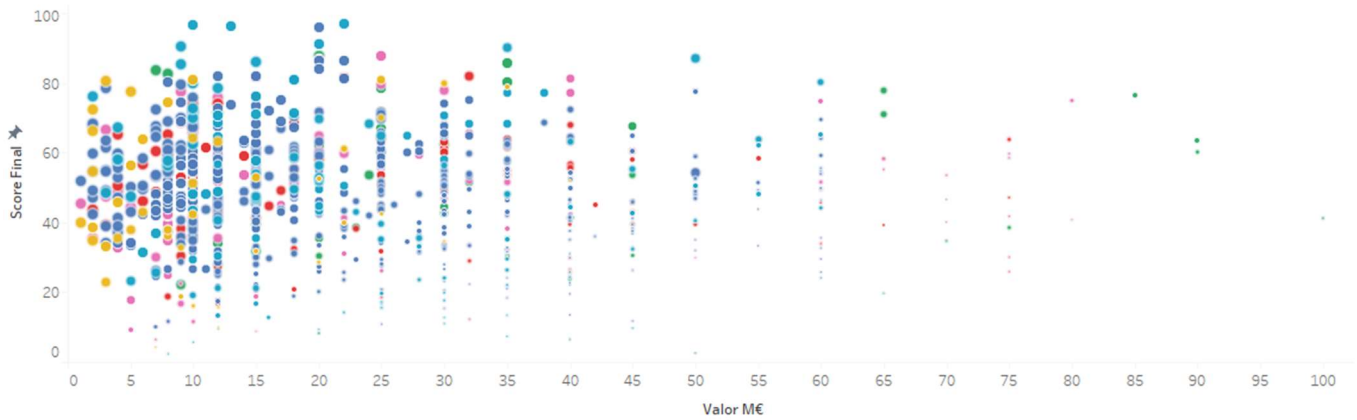

Distribución del score Final por Rol Táctico

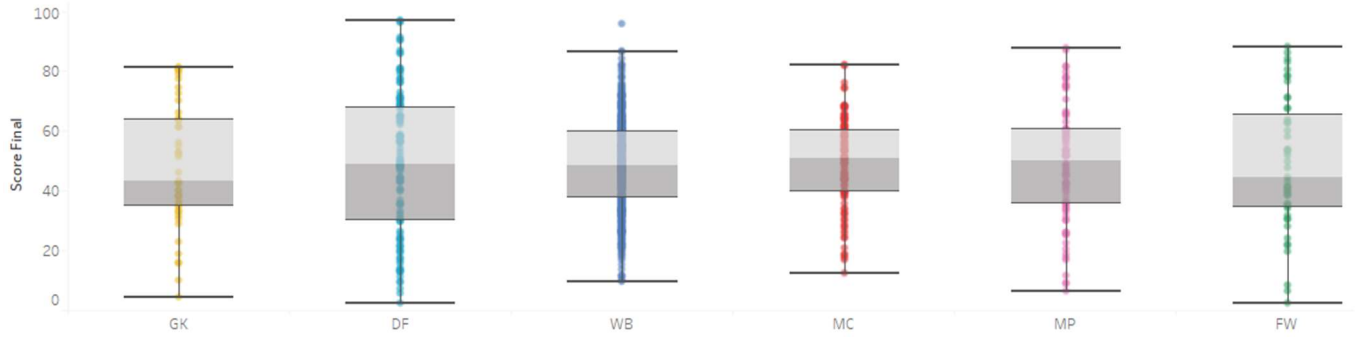

PLANIFICACIÓN ESTRATÉGICA DEL ONCE IDEAL

Modelo 1-3-4-2-1 | Inversión 337M€

Valor VS Coste por línea

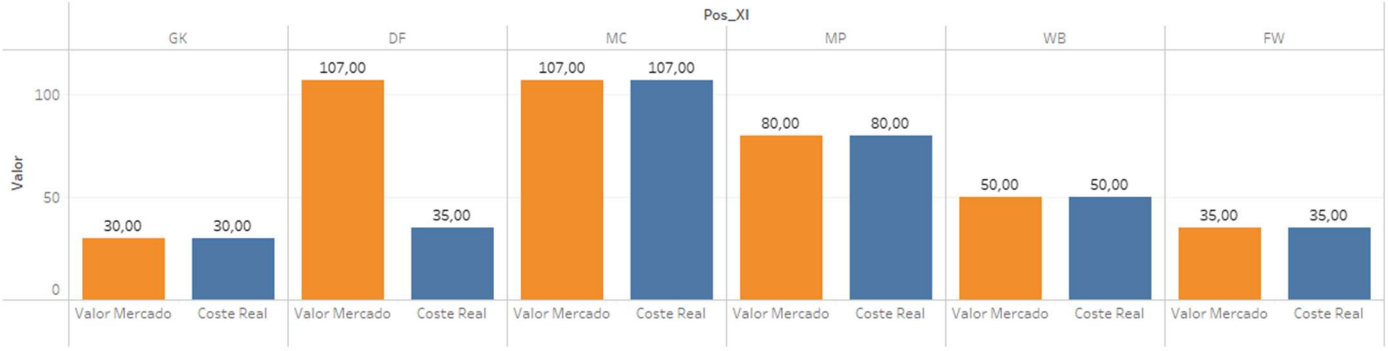
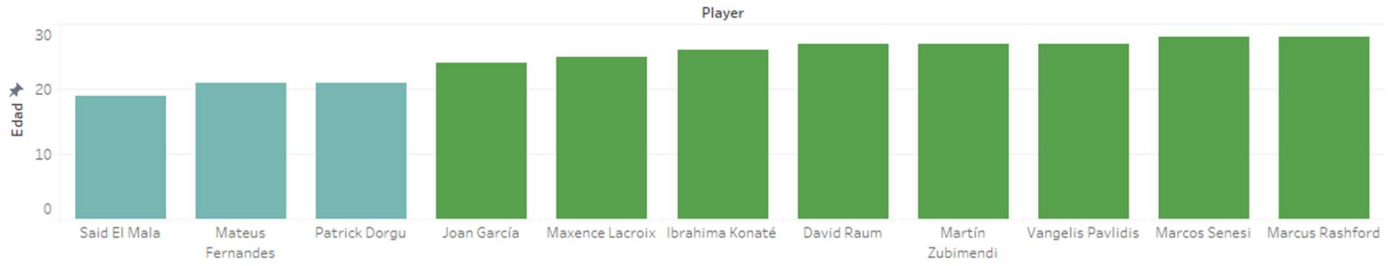
Estructura Generacional del Once Ideal